《深度学习》实验报告

唐小卉　10215501437　数据科学与大数据技术 数据科学与工程学院

一、实验环境

Python 3.9

特殊代码库：

torch (PyTorch): 用于深度学习模型的构建和训练。

tqdm: 用于显示循环的进度条。

numpy: 用于数值计算。

json: 用于读取和写入 JSON 文件。

os: 用于执行压缩操作。

二、实验过程

1. 数据预处理部分

(1) 读取 JSON 文件：

使用 read_json 函数读取训练集、测试集和文档集数据。

```
def read_json(file_path):
    ''' 读取 json 文件 '''
    with open(file_path, 'r') as file:
        data = json.load(file)
    return data
```

(2) 筛选数据：过滤掉 evidence_list 为空的训练数据。（上课时也说明过有少量数据是空的）

```
origin_data = read_json('input/query_trainset.json')
data = [item for item in origin_data if item['evidence_list'] != []]
```

2. 模型构建

首先说一下我选择模型的逻辑，从观察数据集能看出，数据集并不是传统意义上的语言数据集，而是经过了一定抽象化后的序列数据，那么对于序列数据来说比较好的模型有 LSTM 和 GRU，我最开始使用了 GRU 来进行本次实验，但是 GRU

对输入序列要求长度一致，但是我们的数据集达不到这个要求，而且我个人认为数据集本身并不算优秀，如果强行对齐或者删减会导致效果更差，所以最后用了LSTM，然后参考了之前的注意力机制实验加入了一个简单的 Attention 层。

Rerank 方面比较简单，我本来考虑使用 BM25 或者 TF-IDF，但是在实践操作的时候我发现他们俩其实不适用于本次 Tokenizer 之后的数据集，所以最终我选择了 Jaccard 相似度和余弦相似度结合来算（其实欧氏距离等计算方式差距也是不大的，我都有试验过，基本没有什么差别）

(1) 模型架构：

输入层：输入维度设置为 1024

LSTM 层：使用三层双向 LSTM 层，隐藏层维度为 128

注意力机制：使用线性层进行注意力权重的计算。（其实也尝试了更复杂的 Attention，但是效果不好，后续就简化为之前实验里的线性层了）

全连接层：将注意力加权后的输出通过全连接层进行映射，输出维度为 1024。

尝试过添加 dropout，但效果一般，后期去掉了。

```python
class CustomLSTMModel(nn.Module):
    def __init__(self, input_dim, hidden_dim, output_dim, num_layers=3):
        super(CustomLSTMModel, self).__init__()
        self.hidden_dim = hidden_dim
        self.num_layers = num_layers
        self.lstm = nn.LSTM(input_dim, hidden_dim, num_layers, batch_first=True, bidirection
        self.fc = nn.Linear(hidden_dim * 2, output_dim)
        self.attn = nn.Linear(hidden_dim * 2, 1)

    def forward(self, x):
        x = x.unsqueeze(0)
        h0 = torch.zeros(self.num_layers * 2, x.size(0), self.hidden_dim).to(x.device)
        c0 = torch.zeros(self.num_layers * 2, x.size(0), self.hidden_dim).to(x.device)
        out, _ = self.lstm(x, (h0, c0))

        attn_weights = torch.nn.functional.softmax(self.attn(out), dim=1)
        attn_output = torch.sum(attn_weights * out, dim=1)
        output = self.fc(attn_output)
        return output
```

以下是对这个模型的详细解释：

1. 初始化

- input_dim: 输入特征的维度。

- hidden_dim: LSTM 隐藏层的维度。
- output_dim: 模型输出的维度。
- num_layers: LSTM 层数，默认为 3。

在初始化方法中，定义了模型的各个部分：

- self.lstm: 一个双向的 LSTM 网络，输入维度为 input_dim，隐藏层维度为 hidden_dim,层数为 num_layers。因为是双向 LSTM,所以 LSTM 的输出维度会是 `hidden_dim * 2`。
- self.fc: 一个全连接层，将 hidden_dim * 2 维度的特征映射到 output_dim 维度。
- self.attn: 一个线性层，用于计算注意力权重。

2. 前向传播

- 输入 x: x 形状(batch_size, seq_length, input_dim)。

在 forward 方法中，完成了以下步骤：

1：扩展输入维度

$$x = x.unsqueeze(0)$$

将 x 的第一个维度添加一维，使其形状从 (seq_length, input_dim)变为 (1, seq_length, input_dim)，即模拟一个批次大小为 1 的情况。

2：初始化 LSTM 隐状态和细胞状态

*h0 = torch.zeros(self.num_layers * 2, x.size(0), self.hidden_dim).to(x.device)*

*c0 = torch.zeros(self.num_layers * 2, x.size(0), self.hidden_dim).to(x.device)*

初始化 LSTM 的初始隐状态 h0 和细胞状态 c0，维度为(num_layers * 2, batch_size, hidden_dim)。因为是双向 LSTM，所以乘以 2。

3：通过 LSTM 层

将输入 x 和状态(h0, c0)传入 LSTM 层，得到输出 out，形状为 (batch_size,

seq_length, hidden_dim * 2)。

4：计算注意力权重

attn_weights = torch.nn.functional.softmax(self.attn(out), dim=1)

通过线性层 self.attn 计算每个时间步的注意力权重，然后使用 softmax 函数进行归一化，确保权重和为 1。输出 attn_weights 形状为(batch_size, seq_length, 1)。

5：应用注意力机制

*attn_output = torch.sum(attn_weights * out, dim=1)*

计算加权后的 LSTM 输出 attn_output，形状为 (batch_size, hidden_dim*2)。这是通过对时间步维度 seq_length 进行加权求和实现的。

6：通过全连接层

output = self.fc(attn_output)

将注意力机制后的输出通过全连接层 self.fc 映射到最终的输出维度 output_dim，得到最终的输出 output。

这个模型结合了双向 LSTM 和注意力机制的优点：

- 双向 LSTM 能够捕捉输入序列的上下文信息，因为它不仅考虑了从前到后的依赖关系，还考虑了从后到前的依赖关系。
- 注意力机制能够让模型在计算输出时关注输入序列中的重要部分，而不是等权重地对待每一个时间步。这在长序列处理中尤其重要。

(2) 相似度计算：为了更好地检索文档，结合了 Cosine 相似度和 Jaccard 相似度

```python
def jaccard_similarity(query_embedding, document_embeddings):
    intersection = torch.sum(query_embedding * document_embeddings, dim=1)
    union = torch.sum(query_embedding + document_embeddings > 0, dim=1)
    jaccard = intersection / (union + 1e-8)  # 加上一个小值以避免除以零
    return jaccard
```

(3) 模型训练

初始化模型、损失函数和优化器，此处使用均方误差损失函数（MSELoss）和 Adam 优化器进行模型训练

```python
input_size = 1024
hidden_size = 128
output_size = 1024
model = CustomLSTMModel(input_size, hidden_size, output_size).to(device)
optimizer = optim.Adam(model.parameters(), lr=0.001)
criterion = nn.MSELoss()
```

对每个 epoch，遍历训练数据，并计算损失进行反向传播和优化。（epoch 的最佳值一直没能找到，目前最高版本的 epoch 为 1500）

```python
num_epochs = 50
for epoch in range(num_epochs):
    total_loss = 0
    for item in data:
        query_embedding = torch.tensor(item['query_embedding'], dtype=torch.float32).to(device)
        evidence_embeddings = torch.stack(
            [torch.tensor(doc['fact_embedding'], dtype=torch.float32).to(device) for doc in item['evidence_list']])

        optimizer.zero_grad()
        query_embedding = query_embedding.unsqueeze(0)

        output = model(query_embedding)
        if evidence_embeddings.numel() > 0:
            loss = criterion(output, evidence_embeddings.mean(dim=0).unsqueeze(0))
            loss.backward()
            optimizer.step()
            total_loss += loss.item()

    print(f'Epoch {epoch + 1}, Loss: {total_loss / len(data)}')
```

三、实验结果

Recall@3:0.5042

MRR@3:0.3728

Loss 变化曲线：

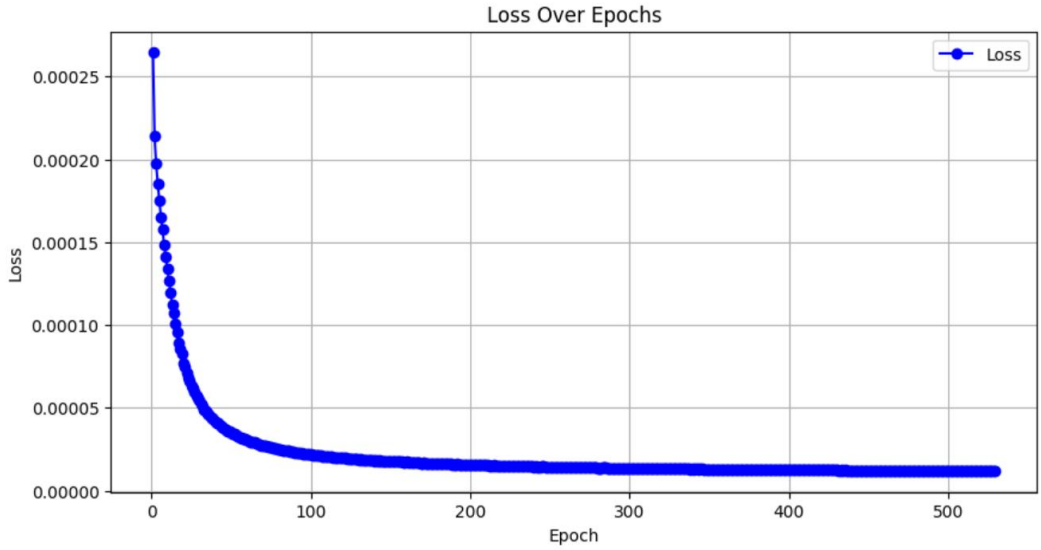

总结：

可以明显看出本次实验是有明显不足的，Recall 和 MRR 都比较低，如果模型选择已经是最优的话，那么参数可能不是最优的，或者 Attention 层没有进行进一步的尝试，导致学习不充分。效果不好的原因多种多样，可能还需要更多的时间去探索。

其实在本次实验的过程中我真的尝试了多种多样的模型，从最简单的余弦相似度再到 BM_25,TF-IDF,BERT，神经网络，注意力机制等等，几乎所有课上学过的内容我都有去尝试，但还是没能得到很好的结果，后续我也标注了数据的起始符号和终止符号，也进行了各种各样的处理，但随着越来越优化，模型越来越强大，反而造成结果变得更差，甚至结果一度达到了 0。这段时间一直有竭尽全力去提升 MRR 和 Recall，但效果微乎其微，但我觉得我也问心无愧了，日后还是继续加油吧。